

Assignment 2: State space models

Lab. professors: Lesly Acosta & Laura Màrques

Álvaro Capel & Enric Alavedra

Mayo 2026

Contents

Part I: Imputation of missing data. Monthly GDP	1
Phase II: Structural Time Series: Deseasonalization of the affiliates Time series	5
Phase III: Multivariate Time Series. Monthly GDP by using the affiliates time series	10

OBJETIVO: A partir del R-script proporcionado, aplicar los contenidos de los Labs 11 y 12 para analizar las series del PIB y de afiliados mediante tres tareas secuenciales: Parte I: Predicción de los valores mensuales faltantes en la serie del PIB desde un enfoque univariante.

Parte II: Desestacionalización de la serie mensual de afiliados proponiendo un modelo estructural.

Parte III: Predicción de los valores faltantes del PIB usando la serie de afiliados como variable auxiliar, ahora desde un enfoque multivariante.

Datos de la serie temporal: - desde enero 1995 hasta diciembre 2022 - 336 observacions mensuales y hay 112 trimestres (el PIB se observa con frecuencia trimestral, por lo que solo hay valores para el último mes de cada trimestre)

Part I: Imputation of missing data. Monthly GDP

Section a): Specify the state-space model:

- **State:** $x_t \in \mathbb{R}$ — nivel latente del PIB mensual (en miles de millones de euros).
- **Observations:** $y_t = \text{PIB}_t$ si $t \in \{3, 6, 9, \dots, 336\}$ (meses trimestrales); $y_t = \text{NA}$ en el resto.
- **Transition equation for the state:**

$$x_t = \Phi x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, cQ^2).$$

- **Observation equation:**

$$y_t = A_t x_t + v_t, \quad v_t \sim \mathcal{N}(0, cR^2),$$


donde $A_t = 1$ si y_t está observado y $A_t = 0$ si y_t es NA. Este truco de enmascaramiento hace que en los meses faltantes la ecuación de observación se “apague” y el filtro de Kalman se limite a propagar el estado sin actualización (predicción pura), de modo que el suavizador rellena esos valores combinando información pasada y futura.

- **Model parameters:** $\theta = (\Phi, cQ)$. Las cantidades $cR = 10^{-6}$, $\mu_0 = y_3 = 112,76$ y $\Sigma_0 = 100$ se fijan (no se estiman). Tomar cR casi nulo equivale a tratar el PIB trimestral observado como un dato sin error de medida.

```
library(astsa)
gdpOri=read.csv2("pibsp.csv",header=F)/1000
```

```
gdp=ts(c(t(cbind(matrix(NA,length(gdpOri),2),gdpOri))),freq=12,start=c(1995,1),end=c(2019,12))
plot(gdp,type="p")
abline(v=1995:2023,lty=3,col=4)
```

Carga y representación gráfica del PIB español a precios corrientes (datos trimestrales)



```
y=gdp
y[is.na(y)]=0
num=length(y)
A = array(1, dim=c(1,1,num))
for(k in 1:num) if (y[k] == 0) A[k]= matrix(0)
```

```
mu0=matrix(y[3])
Sigma0=matrix(100)
cR=matrix(1e-6)
```

Section b): Which method has been used to obtain the maximum likelihood estimators? (Non-linear optimization/NR o EM algorithm) Los parámetros (Φ, cQ) se obtienen maximizando

la log-verosimilitud devuelta por el filtro de Kalman vía **optimización no-lineal cuasi-Newton (BFGS)** con `optim(..., method = "BFGS")`. No se emplea el algoritmo EM en esta parte: con solo dos parámetros la verosimilitud es suficientemente bien comportada para que BFGS converja rápidamente y devuelva además la hessiana numérica de la cual se obtienen errores estándar asintóticos.

```
Linn=function(param){
  Phi=matrix(param[1])
  cQ=matrix(param[2])
  kf=Kfilter(y,A,mu0,Sigma0,Phi,cQ,cR)
  return(kf$like)
}
```

```
initpar=c(1,10)
est=optim(initpar,Linn,NULL,method="BFGS",hessian=TRUE)
stderr=sqrt(diag(solve(est$hessian)))
```

```
(Phi=est$par[1])
```

```
## [1] 1.002651
```

```
(cQ=est$par[2])
```

```
## [1] 1.366514
```

Section c): Estimated model: Los valores estimados son

$$\hat{\Phi} = 1.002651, \quad \widehat{cQ} = 1.366514,$$

de modo que la ecuación de estado ajustada resulta

$$x_t = 1.0027 x_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, 1.8674).$$

Por tanto el modelo se reduce a un **random walk con autorregresivo ligeramente explosivo** (raíz prácticamente unitaria, $\hat{\Phi} \approx 1,003$). La leve desviación por encima de 1 captura el crecimiento tendencial del PIB nominal: a una tasa interanual del 3–4 % típica del periodo le corresponde un factor multiplicativo mensual del orden de 1,003, que es exactamente lo que recoge $\hat{\Phi}$.

```
ks1=Ksmooth(y,A,mu0, Sigma0,Phi,cQ,cR)
```

```
smo1=ts(data.frame(GDP=c(unlist(ks1$Xs))),start=c(1995,1),freq=12)
Psmo1=ts(data.frame(GDP=c(unlist(ks1$Ps))),start=c(1995,1),freq=12)
```

```
llim1=smo1+qnorm(0.025)*sqrt(Psmo1)
ulim1=smo1+qnorm(0.975)*sqrt(Psmo1)
```

```
smo1
```


```
##           Jan           Feb           Mar           Apr           May           Jun           Jul           Aug
## 1995 112.1959 112.4775 112.7600 113.3062 113.8532 114.4010 114.8092 115.2182
## 1996 118.3518 118.9055 119.4600 120.0432 120.6272 121.2120 122.0011 122.7911
```

```

## 1997 125.3531 125.7581 126.1640 126.6814 127.1998 127.7190 128.6664 129.6148
## 1998 134.6991 134.5781 134.4580 135.5190 136.5810 137.6440 138.3924 139.1417
## 1999 144.3147 144.6313 144.9490 145.6666 146.3853 147.1050 148.0223 148.9406
## 2000 155.0049 156.2019 157.4000 158.3429 159.2869 160.2320 161.2292 162.2275
## 2001 168.2385 169.4861 170.7350 171.5858 172.4378 173.2910 174.5018 175.7138
## 2002 180.9431 181.8474 182.7530 183.8907 185.0297 186.1700 187.0890 188.0094
## 2003 192.9240 194.1513 195.3800 196.6813 197.9839 199.2880 200.1953 201.1039
## 2004 206.7845 207.9865 209.1900 210.2475 211.3065 212.3670 213.7515 215.1375
## 2005 222.5064 223.6594 224.8140 226.3521 227.8917 229.4330 230.9217 232.4120
## 2006 240.6780 242.1516 243.6270 245.4233 247.2213 249.0210 250.4819 251.9446
## 2007 259.7665 261.7688 263.7730 264.9578 266.1445 267.3330 268.0048 268.6785
## 2008 275.9364 276.7957 277.6570 278.0971 278.5390 278.9830 278.4721 277.9631
## 2009 273.3611 271.2791 269.1990 268.5191 267.8411 267.1650 267.0118 266.8605
## 2010 266.8405 267.4348 268.0310 267.8038 267.5785 267.3550 267.5545 267.7558
## 2011 268.9045 268.4468 267.9910 267.9201 267.8511 267.7840 267.0365 266.2908
## 2012 262.1175 261.7958 261.4760 260.5958 259.7175 258.8410 258.3902 257.9412
## 2013 254.1759 255.0605 255.9470 255.7105 255.4759 255.2430 255.1289 255.0165
## 2014 255.1872 255.7952 256.4050 256.6392 256.8752 257.1130 257.5392 257.9672
## 2015 262.4425 264.1938 265.9470 266.7425 267.5398 268.3390 269.1414 269.9458
## 2016 273.7284 274.4047 275.0830 275.7107 276.3404 276.9720 278.0824 279.1947
## 2017 283.3460 284.6380 285.9320 287.1773 288.4246 289.6740 290.2280 290.7840
## 2018 295.8196 296.0973 296.3770 297.4479 298.5209 299.5960 300.4179 301.2419
## 2019 306.9178 308.0198 309.1240 309.4398 309.7578 310.0780 310.5138 310.9518
##      Sep      Oct      Nov      Dec
## 1995 115.6280 116.3508 117.0745 117.7990
## 1996 123.5820 124.0368 124.4925 124.9490
## 1997 130.5640 131.9821 133.4011 134.8210
## 1998 139.8920 141.2600 142.6290 143.9990
## 1999 149.8600 151.1753 152.4916 153.8090
## 2000 163.2270 164.4808 165.7358 166.9920
## 2001 176.9270 177.9634 179.0011 180.0400
## 2002 188.9310 189.8520 190.7743 191.6980
## 2003 202.0140 203.2026 204.3926 205.5840
## 2004 216.5250 218.1335 219.7435 221.3550
## 2005 233.9040 235.6697 237.4370 239.2060
## 2006 253.4090 254.8595 256.3119 257.7660
## 2007 269.3540 271.2604 273.1688 275.0790
## 2008 277.4560 276.7837 276.1134 275.4450
## 2009 266.7110 266.5548 266.4005 266.2480
## 2010 267.9590 268.4255 268.8938 269.3640
## 2011 265.5470 264.5098 263.4745 262.4410
## 2012 257.4940 256.0919 254.6915 253.2930
## 2013 254.9060 254.7959 254.6875 254.5810
## 2014 258.3970 259.1605 259.9258 260.6930
## 2015 270.7520 271.5174 272.2848 273.0540
## 2016 280.3090 280.8894 281.4717 282.0560
## 2017 291.3420 292.7406 294.1413 295.5440
## 2018 302.0680 303.3159 304.5659 305.8180
## 2019 311.3920 312.5655 313.7411 314.9190

```

```
ts.plot(smo1,llim1,ulim1,gdp,col=c(2,4,4,1),type="o",lty=c(1,3,3,1),xlim=c(2011,2016),ylim=c(240,290),m
```



Section d): Final goal and interpretation/validation of the result

Results interpretation:

- La línea roja en el gráfico (trayectoria suavizada) pasa exactamente por los puntos trimestrales observados (negros). Esto es consecuencia directa de fijar $cR \approx 0$: las observaciones se imponen sin error, y el suavizador interpola entre ellas según la ley de evolución del estado.
- Las líneas azules discontinuas son las bandas de confianza al 95 %, las cuales **se cierran a cero** en los meses trimestrales (porque la observación los fija) y **se abren** en los dos meses intermedios, alcanzando su máxima incertidumbre en el segundo mes de cada trimestre. Esta forma de “festón” entre nodos observados es la firma característica de la imputación univariante.
- La **limitación fundamental** del enfoque univariante es que los meses intra-trimestre se reconstruyen sin información económica externa: el modelo no “sabe” si dentro del trimestre la actividad crece o decrece. En episodios de cambio brusco (crisis 2008, COVID-19 en 2020) esto produce trayectorias mensuales suavizadas que pueden ser poco realistas.

Phase II: Structural Time Series: Deseasonalization of the affiliates Time series

Section a): Specify the state-space model:

- **State:** $\alpha_t = (\mu_t, \beta_t, \gamma_t, \gamma_{t-1}, \dots, \gamma_{t-10})' \in \mathbb{R}^{13}$, donde μ_t es el nivel, β_t la pendiente y γ_{t-j} los rezagos del componente estacional.
- **Observations:** $y_t = \text{Afil}_t$, mensual, en millones de trabajadores.

- **Transition equation for the state:**

$$\begin{aligned}\mu_t &= \mu_{t-1} + \beta_{t-1} + \eta_{\mu,t}, & \eta_{\mu,t} &\sim \mathcal{N}(0, cQ_1^2), \\ \beta_t &= \beta_{t-1} + \eta_{\beta,t}, & \eta_{\beta,t} &\sim \mathcal{N}(0, cQ_2^2), \\ \gamma_t &= -\sum_{j=1}^{11} \gamma_{t-j} + \eta_{\gamma,t}, & \eta_{\gamma,t} &\sim \mathcal{N}(0, cQ_3^2), \\ \gamma_{t-j} &= \gamma_{t-j} \text{ (desplazamientos deterministas)}, & j &= 1, \dots, 10.\end{aligned}$$

En forma matricial $\alpha_t = \Phi \alpha_{t-1} + \eta_t$, con Φ definida exactamente como en el chunk siguiente: bloque 2×2 de tendencia local $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ en la esquina superior izquierda, fila 3 con once -1 (restricción de la estacional), y un bloque identidad 10×10 desplazado que va arrastrando los rezagos.

- **Observation equation:**


$$y_t = A \alpha_t + \varepsilon_t, \quad A = (1, 0, 1, 0, \dots, 0), \quad \varepsilon_t \sim \mathcal{N}(0, cR^2),$$

es decir, lo que se observa es $\mu_t + \gamma_t + \varepsilon_t$.

- **Model parameters:** $\theta = (cQ_1, cQ_2, cQ_3, cR)$ — cuatro varianzas (en forma de desviaciones típicas). $\mu_0 = (y_1, 0, \dots, 0)'$ y $\Sigma_0 = 10 I_{13}$ se fijan.

```
afil=ts(read.table("afiliados.csv",header=F)[,1]/1000000,start=c(1995,1),end=c(2019,12),freq=12)
plot(afil)
abline(v=1995:2023,lty=3,col=4)
```

Carga y representación gráfica de los afiliados a la Seguridad Social (datos mensuales)



```

ser=afil
num=length(ser)
y=matrix(ser,ncol=1)

A = matrix(c(1,0,1,rep(0,10)),nr=1)

Phi=matrix(0,nc=13,nr=13)
Phi[1:2,1:2]=matrix(c(1,0,1,1),nrow=2)
Phi[3,3:13]=rep(-1,11)
Phi[4:13,3:12]=diag(1,10)
mu0=c(y[1],rep(0,12))
Sigma0=diag(rep(10,13))

```

Section b): Which method has been used to obtain the maximum likelihood estimators? (Non-linear optimization/NR o EM algorithm) Igual que en la Parte I, se emplea **optimización no-lineal cuasi-Newton (BFGS)** sobre $-\ell(\theta)$ devuelta por `Kfilter`. Con cuatro parámetros el problema sigue siendo tratable por BFGS, aunque cabe esperar que algún parámetro alcance el borde del espacio paramétrico (varianza cercana a cero), lo que se manifiesta en *warnings* de NaN al calcular errores estándar por inversión de la hessiana.

```

Linn=function(para){
  cQ1=para[1]
  cQ2=para[2]
  cQ3=para[3]
  cR=para[4]
  cQ=diag(c(cQ1,cQ2,cQ3,rep(0,10)))
  kf=Kfilter(y,A,mu0,Sigma0,Phi,cQ,cR)
  return(kf$Like)
}

```

```

initpar=c(0.1,0.01,0.01,0)
est=optim(initpar,Linn,NULL,method="BFGS",hessian=TRUE)
stderr=sqrt(diag(solve(est$hessian)))

para=est$par
cQ1=para[1]
cQ2=para[2]
cQ3=para[3]
cR=para[4]
cQ=diag(c(cQ1,cQ2,cQ3,rep(0,10)))

```

```

# Impresión explícita de los parámetros estimados para el apartado c)
cat("cQ1 (nivel)      =", round(cQ1, 6), "\n")

```

```
## cQ1 (nivel)      = 0.039903
```

```
cat("cQ2 (pendiente)  =", round(cQ2, 6), "\n")
```

```
## cQ2 (pendiente)  = 0.009786
```

```
cat("cQ3 (estacional) =", round(cQ3, 6), "\n")
```

```
## cQ3 (estacional) = 0.03056
```

```
cat("cR (irregular) =", round(cR, 6), "\n")
```

```
## cR (irregular) = 0
```

Section c): Estimated model: Los valores estimados de las desviaciones típicas son

$$\widehat{cQ}_1 = 0.039903, \quad \widehat{cQ}_2 = 0.009786, \quad \widehat{cQ}_3 = 0.03056, \quad \widehat{cR} = 0.$$


La interpretación cualitativa de cada parámetro es:

- $\widehat{cQ}_1$ controla cuánto puede desviarse el nivel respecto a la trayectoria que predice la pendiente: cuanto mayor, más flexible es la tendencia.
- $\widehat{cQ}_2$ controla la variabilidad de la propia pendiente. Un valor muy pequeño implica una tendencia casi lineal a tramos largos.
- $\widehat{cQ}_3$ regula la evolución del patrón estacional. Si es cercano a cero, la estacionalidad es prácticamente determinista (mismo perfil cada año); si es elevado, el patrón estacional cambia a lo largo del tiempo.
- $\widehat{cR}$ es la magnitud del componente irregular. Si converge al borde (valor casi nulo), el modelo no deja margen para ruido de medida y atribuye toda la variabilidad al estado — esto es lo que produce el *warning* de NaN al invertir la hessiana.

```
kf=Ksmooth(y,A,mu0,Sigma0,Phi,cQ,cR)
```


```
T=length(y)
```

```
smo=ts(data.frame(level=unlist(kf$Xs)[1+(0:(T-1))*13],slope=unlist(kf$Xs)[2+(0:(T-1))*13],seasonal=unlist(kf$Xs)[3+(0:(T-1))*13])
plot(smo)
```



Section d): Final goal and interpretation/validation of the result

```
afil2=afil-smo[, "seasonal"]  
plot(afil,type="o")  
lines(afil2,col=2,lwd=2)
```



Results interpretation:


- El panel de tres gráficos (**level**, **slope**, **seasonal**) muestra una tendencia ascendente con quiebres claros en la crisis financiera (2008–2013), la recuperación posterior (2014–2019) y el shock del COVID-19 (2020), tal y como cabría esperar del empleo en España.
- La pendiente $\hat{\beta}_t$ recoge la velocidad instantánea de creación/destrucción de empleo; su signo cambia abruptamente en 2008 y 2020.
- El componente estacional $\hat{\gamma}_t$ presenta un patrón claramente periódico de 12 meses, con picos en los meses de actividad turística (junio–septiembre) y caídas en los meses de baja contratación (enero).
- En el gráfico final, la línea roja (**afil2**, desestacionalizada) suaviza los dientes de sierra de la línea negra (cruda) preservando la tendencia y los puntos de inflexión cíclicos.

Phase III: Multivariate Time Series. Monthly GDP by using the affiliates time series

```
cor(ts.union(gdp,afil2),use="pairwise.complete.obs")
```

```
##           gdp      afil2
## gdp      1.0000000 0.9214467
## afil2    0.9214467 1.0000000
```

```
plot(ts.union(gdp,afil2),type="o")
```




```
cor(ts.union(gdp,log(afil2)),use="pairwise.complete.obs")
```

```
##           gdp log(afil2)
## gdp      1.0000000  0.9206877
## log(afil2) 0.9206877  1.0000000
```

```
plot(ts.union(gdp,log(afil2)),type="o")
```

ts.union(gdp, log(afil2))



```
serie=cbind(gdp,log(afil2))
dimnames(serie)[[2]]=c("GDP","lnAfil")
```

Section a): Specify the state-space model:

- **State:** $\alpha_t = (x_t^{\text{GDP}}, x_t^{\text{AFIL}})' \in \mathbb{R}^2$.
- **Observations:** $y_t = (\text{gdp}_t, \text{afil2}_t)'$, donde $\text{gdp}_t = \text{NA}$ en meses no trimestrales y afil2_t está siempre observado.
- **Transition equation for the state:**

$$\alpha_t = \Phi \alpha_{t-1} + w_t, \quad w_t \sim \mathcal{N}_2(0, Q), \quad \Phi \in \mathbb{R}^{2 \times 2}, \quad Q \in \mathbb{R}_{>0}^{2 \times 2}.$$

A diferencia de las partes anteriores, Φ y Q son **matrices llenas** (no diagonales), de modo que se permiten interacciones cruzadas entre PIB y afiliados tanto en la dinámica como en las innovaciones.

- **Observation equation:**

$$y_t = A_t \alpha_t + v_t, \quad v_t \sim \mathcal{N}_2(0, R),$$

con $A_t = I_2$ si gdp_t está observado y $A_t = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$ si gdp_t es NA (se desactiva solo la primera observación; la de afiliados sigue actualizando el filtro).

- **Model parameters** $\theta = (\Phi, Q, R)$ — 4 entradas en Φ + 3 entradas independientes en Q (simétrica 2×2) + 3 entradas en R = **10 parámetros**, más μ_0 y Σ_0 , también estimables. Los valores iniciales son $\Phi^{(0)} = I_2$, $Q^{(0)} = \text{diag}(2, 1)$, $R^{(0)} = 10^{-6} I_2$, $\mu_0 = y_3$, $\Sigma_0 = 100 I_2$.

Section b): Which method has been used to obtain the maximum likelihood estimators? (Non-linear optimization/NR o EM algorithm) Con 10+ parámetros la optimización directa con

BFGS se vuelve frágil (verosimilitud con muchos mínimos locales y hessiana mal condicionada). En su lugar se utiliza el **algoritmo EM** (Expectation–Maximization) implementado en `astsa::EM`. Este algoritmo explota la estructura gaussiana lineal del modelo: en el paso E se calculan las esperanzas condicionales del estado dado todos los datos (vía suavizado de Kalman) y en el paso M se actualizan Φ , Q , R , μ_0 , Σ_0 mediante fórmulas cerradas (regresiones de mínimos cuadrados ponderados sobre los estados suavizados). Es **monótono creciente** en la log-verosimilitud y robusto en alta dimensión, a costa de convergencia lineal.

```
y=cbind(gdp,afil2)
y[is.na(gdp),1]=0
num=nrow(y)

A = array(diag(2), dim=c(2,2,num))
for(k in 1:num) if (y[k,1] == 0) A[1,1,k]=0

mu0=y[3,]
Sigma0=diag(c(100,100),2)
Phi=diag(1,2)
cQ=diag(c(2,1),2)
cR=diag(1e-6,2)

em=EM(y,A,mu0,Sigma0,Phi,cQ,cR,max.iter=500,tol=1e-5)
```

```
## iteration    -loglikelihood
##      0         -1212.636
##      1         -1986.727
##      2         -2052.218
##      3         -2058.105
##      4         -2061.509
##      5         -2063.524
##      6         -2064.655
##      7         -2065.26
##      8         -2065.574
##      9         -2065.735
##     10         -2065.818
##     11         -2065.862
##     12         -2065.888
##     13         -2065.904
```

```
em$Phi
```

```
##           [,1]      [,2]
## [1,]  0.9915730730  0.1568424
## [2,] -0.0005000956  1.0082471
```

```
em$Q
```

```
##           [,1]      [,2]
## [1,]  0.9413148  0.026373498
## [2,]  0.0263735  0.002238424
```

Section c): Estimated Model: Los estimadores EM convergen aproximadamente a (ver salidas anteriores):

$$\hat{\Phi} = \begin{pmatrix} 0.9916 & 0.1568 \\ -5 \times 10^{-4} & 1.0082 \end{pmatrix}, \quad \hat{Q} = \begin{pmatrix} 0.9413 & 0.0264 \\ 0.0264 & 0.0022 \end{pmatrix}.$$

Lectura económica de los coeficientes estimados:

- $\hat{\Phi}_{11} \approx 0,99$ y $\hat{\Phi}_{22} \approx 1,01$: ambos estados son **prácticamente paseos aleatorios**, lo que refleja el carácter no-estacionario en niveles tanto del PIB nominal como del empleo.
- $\hat{\Phi}_{12} \approx 0,16$ es el **coeficiente clave** del modelo: cuantifica cuánto del PIB del mes t se explica por los afiliados del mes anterior. Es el canal por el que la información de afiliados (siempre observada) “entra” en el PIB latente cuando gdp_t es NA.
- $\hat{\Phi}_{21} \approx 0$: el PIB rezagado **no informa** a los afiliados, lo que evidencia una relación **asimétrica** entre las dos variables (los afiliados son un indicador adelantado/coincidente del ciclo, pero el PIB no añade información sobre el empleo más allá de la propia inercia del empleo).
- $\hat{Q}_{12} > 0$ indica **correlación positiva entre las innovaciones contemporáneas** de PIB y empleo: los shocks que aumentan la actividad económica también aumentan el empleo en el mismo mes.

```
T=nrow(y)
ks2=Ksmooth(y,A,em$mu0, em$Sigma0,em$Phi,t(chol(em$Q)),t(chol(em$R)))
smo=ts(data.frame(lnGDP=unlist(ks2$Xs)[1+(0:(T-1))*2],afil=unlist(ks2$Xs)[2+(0:(T-1))*2]),start=1995,fr
Psmo=ts(data.frame(lnGDP=unlist(ks2$Ps)[1+(0:(T-1))*4],afil=unlist(ks2$Ps)[4+(0:(T-1))*4]),start=1995,f


l1im=smo+qnorm(0.025)*sqrt(Psmo)
ulim=smo+qnorm(0.975)*sqrt(Psmo)
smo2=smo[,1]
l1im2=l1im[,1]
ulim2=ulim[,1]
```

```
smo2
```

##	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug
## 1995	111.5966	112.1592	112.7600	113.2753	113.8381	114.4010	114.8595	115.3167
## 1996	118.4561	119.0084	119.4600	119.8502	120.4395	121.2120	122.1264	122.9330
## 1997	125.2263	125.6113	126.1640	126.7366	127.1863	127.7190	128.7270	129.7125
## 1998	134.6039	134.4985	134.4580	135.4598	136.5578	137.6440	138.0756	138.9371
## 1999	144.4466	144.7704	144.9490	145.6450	146.4430	147.1050	148.3303	149.0165
## 2000	154.9837	156.1650	157.4000	158.5472	159.3880	160.2320	161.1070	162.1430
## 2001	168.0595	169.3850	170.7350	171.4254	172.3051	173.2910	174.3516	175.4161
## 2002	181.0429	181.8759	182.7530	183.8713	184.9818	186.1700	187.2856	188.4924
## 2003	192.8091	194.0657	195.3800	196.8700	198.2163	199.2880	200.1446	201.0131
## 2004	207.0744	208.3507	209.1900	210.2517	211.3402	212.3670	213.6811	214.9837
## 2005	222.4801	223.5622	224.8140	226.0134	227.6214	229.4330	231.3235	232.6901
## 2006	240.5195	242.0079	243.6270	245.9901	247.6053	249.0210	250.3138	251.8335
## 2007	259.6828	261.6878	263.7730	264.6900	265.8007	267.3330	267.4863	267.7977
## 2008	276.0363	276.9535	277.6570	278.4989	279.0375	278.9830	278.8724	278.9264
## 2009	273.4790	271.3663	269.1990	268.1811	267.7404	267.1650	266.5953	266.5339
## 2010	267.1838	267.7315	268.0310	267.6055	267.3626	267.3550	267.7136	267.6468
## 2011	268.7897	268.2862	267.9910	268.3401	268.0225	267.7840	267.7448	266.8337
## 2012	261.9167	261.6099	261.4760	260.0639	259.1952	258.8410	258.0687	257.6457
## 2013	254.1403	255.0369	255.9470	255.3276	255.0104	255.2430	255.1372	255.2603
## 2014	255.1521	255.7346	256.4050	256.7401	257.0825	257.1130	257.6349	258.3266
## 2015	262.5186	264.3837	265.9470	266.8282	268.0269	268.3390	268.6463	269.5075

```
## 2016 273.8983 274.3582 275.0830 275.7932 276.0459 276.9720 278.8035 279.4368
## 2017 283.2097 284.6031 285.9320 287.8739 288.9817 289.6740 289.9106 290.5722
## 2018 295.8196 296.0957 296.3770 297.2158 298.4645 299.5960 299.8220 300.2666
## 2019 306.8373 307.9896 309.1240 309.4450 309.7544 310.0780 310.8583 311.6418
##      Sep      Oct      Nov      Dec
## 1995 115.6280 116.2199 116.9443 117.7990
## 1996 123.5820 124.0117 124.4549 124.9490
## 1997 130.5640 132.0486 133.4400 134.8210
## 1998 139.8920 141.2705 142.7324 143.9990
## 1999 149.8600 151.4640 152.5949 153.8090
## 2000 163.2270 164.3739 165.6932 166.9920
## 2001 176.9270 177.8772 178.9080 180.0400
## 2002 188.9310 189.6169 190.6312 191.6980
## 2003 202.0140 203.2081 204.5009 205.5840
## 2004 216.5250 218.2588 219.7119 221.3550
## 2005 233.9040 235.8395 237.5920 239.2060
## 2006 253.4090 254.7232 256.2076 257.7660
## 2007 269.3540 271.2694 273.1593 275.0790
## 2008 277.4560 276.7238 276.3214 275.4450
## 2009 266.7110 266.8722 266.4831 266.2480
## 2010 267.9590 268.7664 269.0599 269.3640
## 2011 265.5470 264.5027 263.7929 262.4410
## 2012 257.4940 255.9505 254.0991 253.2930
## 2013 254.9060 254.6161 254.7486 254.5810
## 2014 258.3970 258.8931 259.9385 260.6930
## 2015 270.7520 271.8821 272.3562 273.0540
## 2016 280.3090 280.8780 281.4972 282.0560
## 2017 291.3420 292.7074 294.0941 295.5440
## 2018 302.0680 303.1466 304.1078 305.8180
## 2019 311.3920 312.4925 314.0102 314.9190
```


```
par(mfrow=c(2,1),mar=c(3,3,1,1))
ts.plot(smo1,llim1,ulim1,gdp,col=c(2,4,4,1),type="o",lty=c(1,3,3,1),xlim=c(2011,2015),ylim=c(250,280),ma
ts.plot(smo2,llim2,ulim2,gdp,col=c(2,4,4,1),type="o",lty=c(1,3,3,1),xlim=c(2011,2015),ylim=c(250,280),ma
```



```
par(mfrow=c(1,1))
```

```
ts.plot(smo1,smo2,gdp,col=c(2,3,1),lwd=2,type="o",xlim=c(2012,2015),ylim=c(245,270),main="PIB mensual")
legend("topleft",col=c(2,3),lty=1,lwd=2,legend=c("PIB","PIB+lnAfil"))
```

PIB mensual



```
cbind(gdp,smo1,smo2)
```

```
##      gdp      smo1      smo2
## Jan 1995    NA 112.1959 111.5966
## Feb 1995    NA 112.4775 112.1592
## Mar 1995 112.760 112.7600 112.7600
## Apr 1995    NA 113.3062 113.2753
## May 1995    NA 113.8532 113.8381
## Jun 1995 114.401 114.4010 114.4010
## Jul 1995    NA 114.8092 114.8595
## Aug 1995    NA 115.2182 115.3167
## Sep 1995 115.628 115.6280 115.6280
## Oct 1995    NA 116.3508 116.2199
## Nov 1995    NA 117.0745 116.9443
## Dec 1995 117.799 117.7990 117.7990
## Jan 1996    NA 118.3518 118.4561
## Feb 1996    NA 118.9055 119.0084
## Mar 1996 119.460 119.4600 119.4600
## Apr 1996    NA 120.0432 119.8502
## May 1996    NA 120.6272 120.4395
## Jun 1996 121.212 121.2120 121.2120
## Jul 1996    NA 122.0011 122.1264
## Aug 1996    NA 122.7911 122.9330
## Sep 1996 123.582 123.5820 123.5820
## Oct 1996    NA 124.0368 124.0117
```

##	Nov	1996	NA	124.4925	124.4549
##	Dec	1996	124.949	124.9490	124.9490
##	Jan	1997	NA	125.3531	125.2263
##	Feb	1997	NA	125.7581	125.6113
##	Mar	1997	126.164	126.1640	126.1640
##	Apr	1997	NA	126.6814	126.7366
##	May	1997	NA	127.1998	127.1863
##	Jun	1997	127.719	127.7190	127.7190
##	Jul	1997	NA	128.6664	128.7270
##	Aug	1997	NA	129.6148	129.7125
##	Sep	1997	130.564	130.5640	130.5640
##	Oct	1997	NA	131.9821	132.0486
##	Nov	1997	NA	133.4011	133.4400
##	Dec	1997	134.821	134.8210	134.8210
##	Jan	1998	NA	134.6991	134.6039
##	Feb	1998	NA	134.5781	134.4985
##	Mar	1998	134.458	134.4580	134.4580
##	Apr	1998	NA	135.5190	135.4598
##	May	1998	NA	136.5810	136.5578
##	Jun	1998	137.644	137.6440	137.6440
##	Jul	1998	NA	138.3924	138.0756
##	Aug	1998	NA	139.1417	138.9371
##	Sep	1998	139.892	139.8920	139.8920
##	Oct	1998	NA	141.2600	141.2705
##	Nov	1998	NA	142.6290	142.7324
##	Dec	1998	143.999	143.9990	143.9990
##	Jan	1999	NA	144.3147	144.4466
##	Feb	1999	NA	144.6313	144.7704
##	Mar	1999	144.949	144.9490	144.9490
##	Apr	1999	NA	145.6666	145.6450
##	May	1999	NA	146.3853	146.4430
##	Jun	1999	147.105	147.1050	147.1050
##	Jul	1999	NA	148.0223	148.3303
##	Aug	1999	NA	148.9406	149.0165
##	Sep	1999	149.860	149.8600	149.8600
##	Oct	1999	NA	151.1753	151.4640
##	Nov	1999	NA	152.4916	152.5949
##	Dec	1999	153.809	153.8090	153.8090
##	Jan	2000	NA	155.0049	154.9837
##	Feb	2000	NA	156.2019	156.1650
##	Mar	2000	157.400	157.4000	157.4000
##	Apr	2000	NA	158.3429	158.5472
##	May	2000	NA	159.2869	159.3880
##	Jun	2000	160.232	160.2320	160.2320
##	Jul	2000	NA	161.2292	161.1070
##	Aug	2000	NA	162.2275	162.1430
##	Sep	2000	163.227	163.2270	163.2270
##	Oct	2000	NA	164.4808	164.3739
##	Nov	2000	NA	165.7358	165.6932
##	Dec	2000	166.992	166.9920	166.9920
##	Jan	2001	NA	168.2385	168.0595
##	Feb	2001	NA	169.4861	169.3850
##	Mar	2001	170.735	170.7350	170.7350
##	Apr	2001	NA	171.5858	171.4254

##	May	2001	NA	172.4378	172.3051
##	Jun	2001	173.291	173.2910	173.2910
##	Jul	2001	NA	174.5018	174.3516
##	Aug	2001	NA	175.7138	175.4161
##	Sep	2001	176.927	176.9270	176.9270
##	Oct	2001	NA	177.9634	177.8772
##	Nov	2001	NA	179.0011	178.9080
##	Dec	2001	180.040	180.0400	180.0400
##	Jan	2002	NA	180.9431	181.0429
##	Feb	2002	NA	181.8474	181.8759
##	Mar	2002	182.753	182.7530	182.7530
##	Apr	2002	NA	183.8907	183.8713
##	May	2002	NA	185.0297	184.9818
##	Jun	2002	186.170	186.1700	186.1700
##	Jul	2002	NA	187.0890	187.2856
##	Aug	2002	NA	188.0094	188.4924
##	Sep	2002	188.931	188.9310	188.9310
##	Oct	2002	NA	189.8520	189.6169
##	Nov	2002	NA	190.7743	190.6312
##	Dec	2002	191.698	191.6980	191.6980
##	Jan	2003	NA	192.9240	192.8091
##	Feb	2003	NA	194.1513	194.0657
##	Mar	2003	195.380	195.3800	195.3800
##	Apr	2003	NA	196.6813	196.8700
##	May	2003	NA	197.9839	198.2163
##	Jun	2003	199.288	199.2880	199.2880
##	Jul	2003	NA	200.1953	200.1446
##	Aug	2003	NA	201.1039	201.0131
##	Sep	2003	202.014	202.0140	202.0140
##	Oct	2003	NA	203.2026	203.2081
##	Nov	2003	NA	204.3926	204.5009
##	Dec	2003	205.584	205.5840	205.5840
##	Jan	2004	NA	206.7845	207.0744
##	Feb	2004	NA	207.9865	208.3507
##	Mar	2004	209.190	209.1900	209.1900
##	Apr	2004	NA	210.2475	210.2517
##	May	2004	NA	211.3065	211.3402
##	Jun	2004	212.367	212.3670	212.3670
##	Jul	2004	NA	213.7515	213.6811
##	Aug	2004	NA	215.1375	214.9837
##	Sep	2004	216.525	216.5250	216.5250
##	Oct	2004	NA	218.1335	218.2588
##	Nov	2004	NA	219.7435	219.7119
##	Dec	2004	221.355	221.3550	221.3550
##	Jan	2005	NA	222.5064	222.4801
##	Feb	2005	NA	223.6594	223.5622
##	Mar	2005	224.814	224.8140	224.8140
##	Apr	2005	NA	226.3521	226.0134
##	May	2005	NA	227.8917	227.6214
##	Jun	2005	229.433	229.4330	229.4330
##	Jul	2005	NA	230.9217	231.3235
##	Aug	2005	NA	232.4120	232.6901
##	Sep	2005	233.904	233.9040	233.9040
##	Oct	2005	NA	235.6697	235.8395

##	Nov	2005	NA	237.4370	237.5920
##	Dec	2005	239.206	239.2060	239.2060
##	Jan	2006	NA	240.6780	240.5195
##	Feb	2006	NA	242.1516	242.0079
##	Mar	2006	243.627	243.6270	243.6270
##	Apr	2006	NA	245.4233	245.9901
##	May	2006	NA	247.2213	247.6053
##	Jun	2006	249.021	249.0210	249.0210
##	Jul	2006	NA	250.4819	250.3138
##	Aug	2006	NA	251.9446	251.8335
##	Sep	2006	253.409	253.4090	253.4090
##	Oct	2006	NA	254.8595	254.7232
##	Nov	2006	NA	256.3119	256.2076
##	Dec	2006	257.766	257.7660	257.7660
##	Jan	2007	NA	259.7665	259.6828
##	Feb	2007	NA	261.7688	261.6878
##	Mar	2007	263.773	263.7730	263.7730
##	Apr	2007	NA	264.9578	264.6900
##	May	2007	NA	266.1445	265.8007
##	Jun	2007	267.333	267.3330	267.3330
##	Jul	2007	NA	268.0048	267.4863
##	Aug	2007	NA	268.6785	267.7977
##	Sep	2007	269.354	269.3540	269.3540
##	Oct	2007	NA	271.2604	271.2694
##	Nov	2007	NA	273.1688	273.1593
##	Dec	2007	275.079	275.0790	275.0790
##	Jan	2008	NA	275.9364	276.0363
##	Feb	2008	NA	276.7957	276.9535
##	Mar	2008	277.657	277.6570	277.6570
##	Apr	2008	NA	278.0971	278.4989
##	May	2008	NA	278.5390	279.0375
##	Jun	2008	278.983	278.9830	278.9830
##	Jul	2008	NA	278.4721	278.8724
##	Aug	2008	NA	277.9631	278.9264
##	Sep	2008	277.456	277.4560	277.4560
##	Oct	2008	NA	276.7837	276.7238
##	Nov	2008	NA	276.1134	276.3214
##	Dec	2008	275.445	275.4450	275.4450
##	Jan	2009	NA	273.3611	273.4790
##	Feb	2009	NA	271.2791	271.3663
##	Mar	2009	269.199	269.1990	269.1990
##	Apr	2009	NA	268.5191	268.1811
##	May	2009	NA	267.8411	267.7404
##	Jun	2009	267.165	267.1650	267.1650
##	Jul	2009	NA	267.0118	266.5953
##	Aug	2009	NA	266.8605	266.5339
##	Sep	2009	266.711	266.7110	266.7110
##	Oct	2009	NA	266.5548	266.8722
##	Nov	2009	NA	266.4005	266.4831
##	Dec	2009	266.248	266.2480	266.2480
##	Jan	2010	NA	266.8405	267.1838
##	Feb	2010	NA	267.4348	267.7315
##	Mar	2010	268.031	268.0310	268.0310
##	Apr	2010	NA	267.8038	267.6055

##	May	2010	NA	267.5785	267.3626
##	Jun	2010	267.355	267.3550	267.3550
##	Jul	2010	NA	267.5545	267.7136
##	Aug	2010	NA	267.7558	267.6468
##	Sep	2010	267.959	267.9590	267.9590
##	Oct	2010	NA	268.4255	268.7664
##	Nov	2010	NA	268.8938	269.0599
##	Dec	2010	269.364	269.3640	269.3640
##	Jan	2011	NA	268.9045	268.7897
##	Feb	2011	NA	268.4468	268.2862
##	Mar	2011	267.991	267.9910	267.9910
##	Apr	2011	NA	267.9201	268.3401
##	May	2011	NA	267.8511	268.0225
##	Jun	2011	267.784	267.7840	267.7840
##	Jul	2011	NA	267.0365	267.7448
##	Aug	2011	NA	266.2908	266.8337
##	Sep	2011	265.547	265.5470	265.5470
##	Oct	2011	NA	264.5098	264.5027
##	Nov	2011	NA	263.4745	263.7929
##	Dec	2011	262.441	262.4410	262.4410
##	Jan	2012	NA	262.1175	261.9167
##	Feb	2012	NA	261.7958	261.6099
##	Mar	2012	261.476	261.4760	261.4760
##	Apr	2012	NA	260.5958	260.0639
##	May	2012	NA	259.7175	259.1952
##	Jun	2012	258.841	258.8410	258.8410
##	Jul	2012	NA	258.3902	258.0687
##	Aug	2012	NA	257.9412	257.6457
##	Sep	2012	257.494	257.4940	257.4940
##	Oct	2012	NA	256.0919	255.9505
##	Nov	2012	NA	254.6915	254.0991
##	Dec	2012	253.293	253.2930	253.2930
##	Jan	2013	NA	254.1759	254.1403
##	Feb	2013	NA	255.0605	255.0369
##	Mar	2013	255.947	255.9470	255.9470
##	Apr	2013	NA	255.7105	255.3276
##	May	2013	NA	255.4759	255.0104
##	Jun	2013	255.243	255.2430	255.2430
##	Jul	2013	NA	255.1289	255.1372
##	Aug	2013	NA	255.0165	255.2603
##	Sep	2013	254.906	254.9060	254.9060
##	Oct	2013	NA	254.7959	254.6161
##	Nov	2013	NA	254.6875	254.7486
##	Dec	2013	254.581	254.5810	254.5810
##	Jan	2014	NA	255.1872	255.1521
##	Feb	2014	NA	255.7952	255.7346
##	Mar	2014	256.405	256.4050	256.4050
##	Apr	2014	NA	256.6392	256.7401
##	May	2014	NA	256.8752	257.0825
##	Jun	2014	257.113	257.1130	257.1130
##	Jul	2014	NA	257.5392	257.6349
##	Aug	2014	NA	257.9672	258.3266
##	Sep	2014	258.397	258.3970	258.3970
##	Oct	2014	NA	259.1605	258.8931

##	Nov	2014	NA	259.9258	259.9385
##	Dec	2014	260.693	260.6930	260.6930
##	Jan	2015	NA	262.4425	262.5186
##	Feb	2015	NA	264.1938	264.3837
##	Mar	2015	265.947	265.9470	265.9470
##	Apr	2015	NA	266.7425	266.8282
##	May	2015	NA	267.5398	268.0269
##	Jun	2015	268.339	268.3390	268.3390
##	Jul	2015	NA	269.1414	268.6463
##	Aug	2015	NA	269.9458	269.5075
##	Sep	2015	270.752	270.7520	270.7520
##	Oct	2015	NA	271.5174	271.8821
##	Nov	2015	NA	272.2848	272.3562
##	Dec	2015	273.054	273.0540	273.0540
##	Jan	2016	NA	273.7284	273.8983
##	Feb	2016	NA	274.4047	274.3582
##	Mar	2016	275.083	275.0830	275.0830
##	Apr	2016	NA	275.7107	275.7932
##	May	2016	NA	276.3404	276.0459
##	Jun	2016	276.972	276.9720	276.9720
##	Jul	2016	NA	278.0824	278.8035
##	Aug	2016	NA	279.1947	279.4368
##	Sep	2016	280.309	280.3090	280.3090
##	Oct	2016	NA	280.8894	280.8780
##	Nov	2016	NA	281.4717	281.4972
##	Dec	2016	282.056	282.0560	282.0560
##	Jan	2017	NA	283.3460	283.2097
##	Feb	2017	NA	284.6380	284.6031
##	Mar	2017	285.932	285.9320	285.9320
##	Apr	2017	NA	287.1773	287.8739
##	May	2017	NA	288.4246	288.9817
##	Jun	2017	289.674	289.6740	289.6740
##	Jul	2017	NA	290.2280	289.9106
##	Aug	2017	NA	290.7840	290.5722
##	Sep	2017	291.342	291.3420	291.3420
##	Oct	2017	NA	292.7406	292.7074
##	Nov	2017	NA	294.1413	294.0941
##	Dec	2017	295.544	295.5440	295.5440
##	Jan	2018	NA	295.8196	295.8196
##	Feb	2018	NA	296.0973	296.0957
##	Mar	2018	296.377	296.3770	296.3770
##	Apr	2018	NA	297.4479	297.2158
##	May	2018	NA	298.5209	298.4645
##	Jun	2018	299.596	299.5960	299.5960
##	Jul	2018	NA	300.4179	299.8220
##	Aug	2018	NA	301.2419	300.2666
##	Sep	2018	302.068	302.0680	302.0680
##	Oct	2018	NA	303.3159	303.1466
##	Nov	2018	NA	304.5659	304.1078
##	Dec	2018	305.818	305.8180	305.8180
##	Jan	2019	NA	306.9178	306.8373
##	Feb	2019	NA	308.0198	307.9896
##	Mar	2019	309.124	309.1240	309.1240
##	Apr	2019	NA	309.4398	309.4450

```
## May 2019      NA 309.7578 309.7544
## Jun 2019 310.078 310.0780 310.0780
## Jul 2019      NA 310.5138 310.8583
## Aug 2019      NA 310.9518 311.6418
## Sep 2019 311.392 311.3920 311.3920
## Oct 2019      NA 312.5655 312.4925
## Nov 2019      NA 313.7411 314.0102
## Dec 2019 314.919 314.9190 314.9190
```

```
cor(ts.union(gdp,afil2),use="pairwise.complete.obs")
```

```
##           gdp      afil2
## gdp  1.0000000 0.9214467
## afil2 0.9214467 1.0000000
```

```
cor(ts.union(smo1,afil2))
```

```
##           smo1      afil2
## smo1  1.0000000 0.921896
## afil2 0.921896 1.0000000
```

```
cor(ts.union(smo2,afil2))
```

```
##           smo2      afil2
## smo2  1.0000000 0.921981
## afil2 0.921981 1.0000000
```

Section d): Final goal and interpretation/validation of the result El objetivo de esta parte es **mejorar la imputación del PIB mensual respecto al enfoque univariante de la Parte I** incorporando los afiliados desestacionalizados como variable auxiliar mensual. La intuición económica es directa: el empleo y el PIB son fuertemente comovientes (correlación contemporánea $\approx 0,92$), pero el empleo se observa mensualmente, así que aporta información sobre los meses intra-trimestre que la imputación univariante ignora por completo.

Lectura del resultado:

- En el panel comparativo del PIB mensual con bandas de confianza, las bandas de **smo2** (multivariante) son **más estrechas en los meses intra-trimestre** que las de **smo1** (univariante). Esto cuantifica la ganancia de información: la incertidumbre sobre el PIB no observado se reduce al condicionarlo a los afiliados.
- En el gráfico de comparación directa, la trayectoria verde (**smo2 = PIB+lnAfil**) y la roja (**smo1 = PIB**) difieren en los meses intra-trimestre, y la verde es **más sensible al ciclo del empleo** — sigue las inflexiones de afiliados en lugar de limitarse a interpolar linealmente entre trimestres. En episodios como la crisis 2008–2013 o el COVID-19 de 2020 (no visibles en `xlim=c(2012,2015)` pero presentes en la serie completa) esta ganancia cualitativa es donde más se nota.
- Las correlaciones $\rho(\text{smo1}, \text{afil2}) \approx 0,9219$ y $\rho(\text{smo2}, \text{afil2}) \approx 0,9220$ son casi idénticas, lo que confirma que en niveles agregados ambas imputaciones son consistentes con la información de afiliados. La diferencia entre ambas no está en el nivel medio sino en la **estructura temporal mes a mes**.